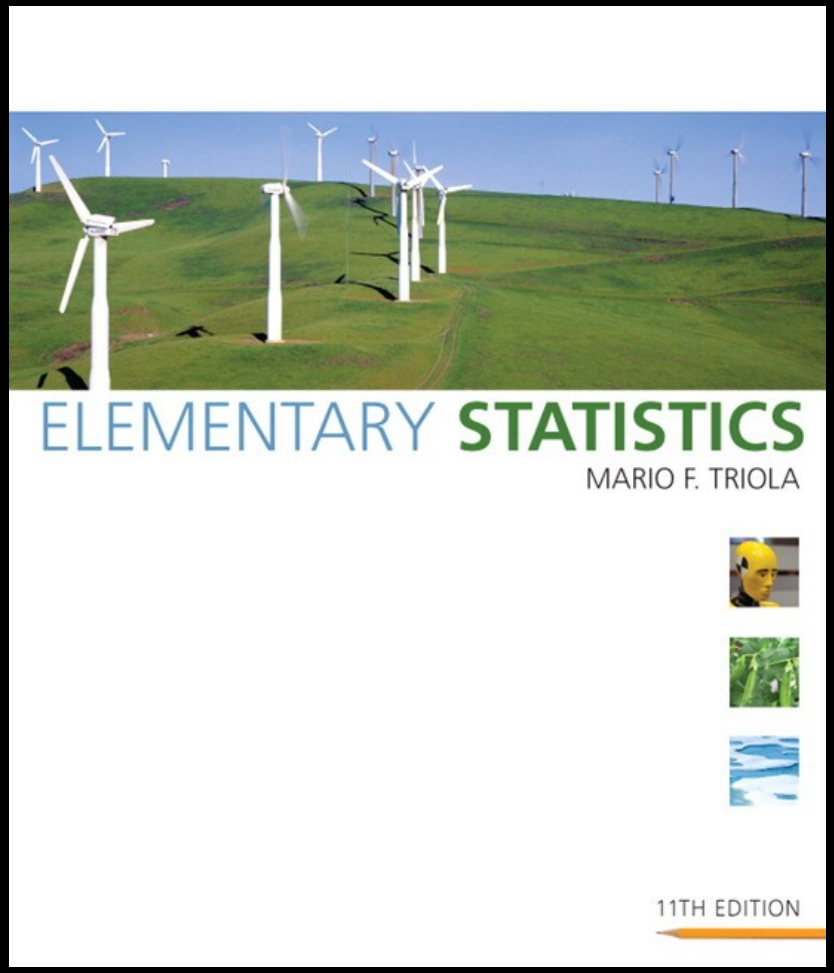
Lecture Slides



Elementary Statistics
Eleventh Edition

and the Triola Statistics Series

by Mario F. Triola

Tradução: Bruno Churata

PEARSON

Capítulo 3
Estatísticas Para Descrever, Explorar e Comparar Dados

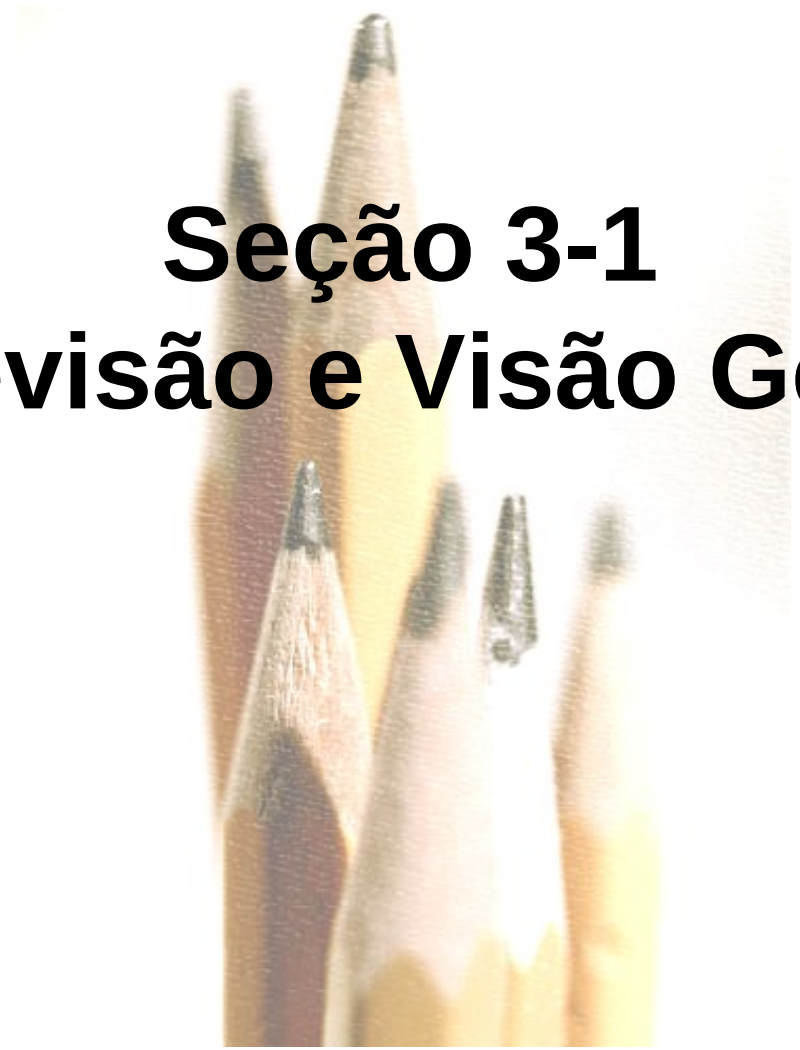
3-1 Revisar e Visualizar

3-2 Medidas do Centro

3-3 Medidas de Variação

3-4 Medidas de Posição Relativa e Boxplots

Seção 3-1
Revisão e Visão Geral



Created by Tom Wegleitner, Centreville, Virginia



Revisão

- **Capítulo 1**

  Distinguir entre população e amostra, parâmetro e bons métodos estatístico de amostragem: *amostra aleatória simples*, coleta de maneira apropriada

- **Capítulo 2**

  Distribuição de frequência: resumindo dados Gráficos projetados para ajudar a entender os dados. Medida de tendência central, variação, distribuição, outliers, características que mudam ao longo do tempo

Visão Geral

- **Estatísticas Importantes**

  Média, mediana, desvio padrão, variância

- **Entendendo e Interpretando**

  essas estatísticas importantes

Visão Geral

- **Estatísticas descritivas**

  Neste capítulo, aprenderemos a resumir ou descrever as características importantes de um conjunto conhecido de dados

- **Estatística inferencial**

  Em capítulos posteriores, aprenderemos a usar dados de amostra para fazer inferências ou generalizações sobre uma população



Seção 3-2
Medidas de Tendência Central

Conceito Chave

Características de tendência central. Medidas de centro, incluindo média e mediana, como ferramentas de análise de dados. Não só determinar o valor de cada medida de centro, mas também interpretar esses valores.

Parte 1

Conceitos Básicos de Medidas de Tendência Central

Medida de Tendência Central

Medida de Tendência Central

o valor localizado no centro (no meio) de um conjunto de dados

Média Aritmética

Média aritmética (Média)

a medida central obtida somando os valores e dividindo o total pelo número de valores

O que a maioria das pessoas chama de média.

Notação

Σ denota a **soma** do conjunto de valores.

x é a **variável** geralmente usada para representar os valores individuais dos dados.

n representa o **número de valores de dados na amostra**.

N representa o **número de valores de dados na população**.

Notação

$\bar{x}$ é pronunciado ‘x-bar’ e denota a média de um conjunto de valores amostrais

$$\bar{x} = \frac{\Sigma x}{n}$$

μ é pronunciado ‘mu’ e denota a média de todos valores na população

$$\mu = \frac{\Sigma x}{N}$$

Média

- **Vantagens**

  É relativamente confiável, as médias de amostras retiradas da mesma população não variam tanto quanto outras medidas de centro. Leva em consideração todos os valores de dados.

- **Desvantagens**

  É sensível a todos os valores dos dados, um valor extremo pode afetá-lo drasticamente; não é uma medida de centro resistente

Mediana

- **Mediana**

  o valor central quando os valores originais são organizados em ordem crescente (ou decrescente) de magnitude

- **muitas vezes denotado por $\tilde{x}$ (pronunciado 'x-til')**

- **não é afetado por um valor extremo - é uma medida do centro resistente**

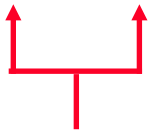
Encontrando a Mediana

Primeiro ordene os valores (organize-os em ordem), siga um destes

1. **Se o número de valores de dados for ímpar, a mediana será o número localizado exatamente no meio da lista.**
2. **Se o número de valores de dados for par, a mediana é encontrada calculando a média dos dois números do meio.**

5.40 1.10 0.42 0.73 0.48 1.10

0.42 0.48 0.73 1.10 1.10 5.40



(em order - number par de valores – meio não exato compartilhado por dois números)

$$\frac{0.73 + 1.10}{2}$$

MEDIANA é 0.915

5.40 1.10 0.42 0.73 0.48 1.10 0.66

0.42 0.48 0.66 0.73 1.10 1.10 5.40

(em order – número par de valores)

meio exato

MEDIANA é 0.73

Moda

- **Moda**
  o valor que ocorre com a maior frequência

O conjunto de dados pode ter um, mais de um ou nenhum moda

Bimodal	**dois valores de dados ocorrem com a mesma maior frequência**
Multimodal	**mais de dois valores de dados ocorrem com a mesma maior frequência**
Sem Modal	**nenhum valor de dados é repetido**

A moda é a única medida de tendência central que pode ser usada com dados nominal

Moda - Exemplos

a. 5.40 1.10 0.42 0.73 0.48 1.10 ⇦ **Moda é 1.10**

b. 27 27 27 55 55 55 88 88 99 ⇦ **Bimodal - 27 & 55**

c. 1 2 3 6 7 8 9 10 ⇦ **Sem Moda**

Definição

- **Ponto Médio**
  o valor intermediário entre os valores máximo e mínimo no conjunto de dados original

$$\text{Ponto Médio} = \frac{\text{maximum value} + \text{minimum value}}{2}$$

Ponto Médio

- **Sensível a extremos**
  porque usa apenas os valores máximo e mínimo, tão raramente usados
- **Característica**

  (1) muito fácil de calcular

  (2) reforça que existem várias formas de definir o centro

  (3) Evita confusão com a mediana

Regra de arredondamento para Medidas de Tendência Central

Arredonde com uma casa decimal a mais do que está presente no conjunto original de valores.

Pensamento Crítico

Pense se os resultados são razoáveis.

Pense no método usado para coletar os dados da amostra.

Parte 2

Além das Noções Básicas de Medidas de Tendência Central

Média de uma distribuição de frequência

Suponha que todos os valores de amostra em cada classe sejam iguais ao ponto médio da classe.

Média de uma distribuição de frequência

use o ponto médio da classe de classes para a variável x

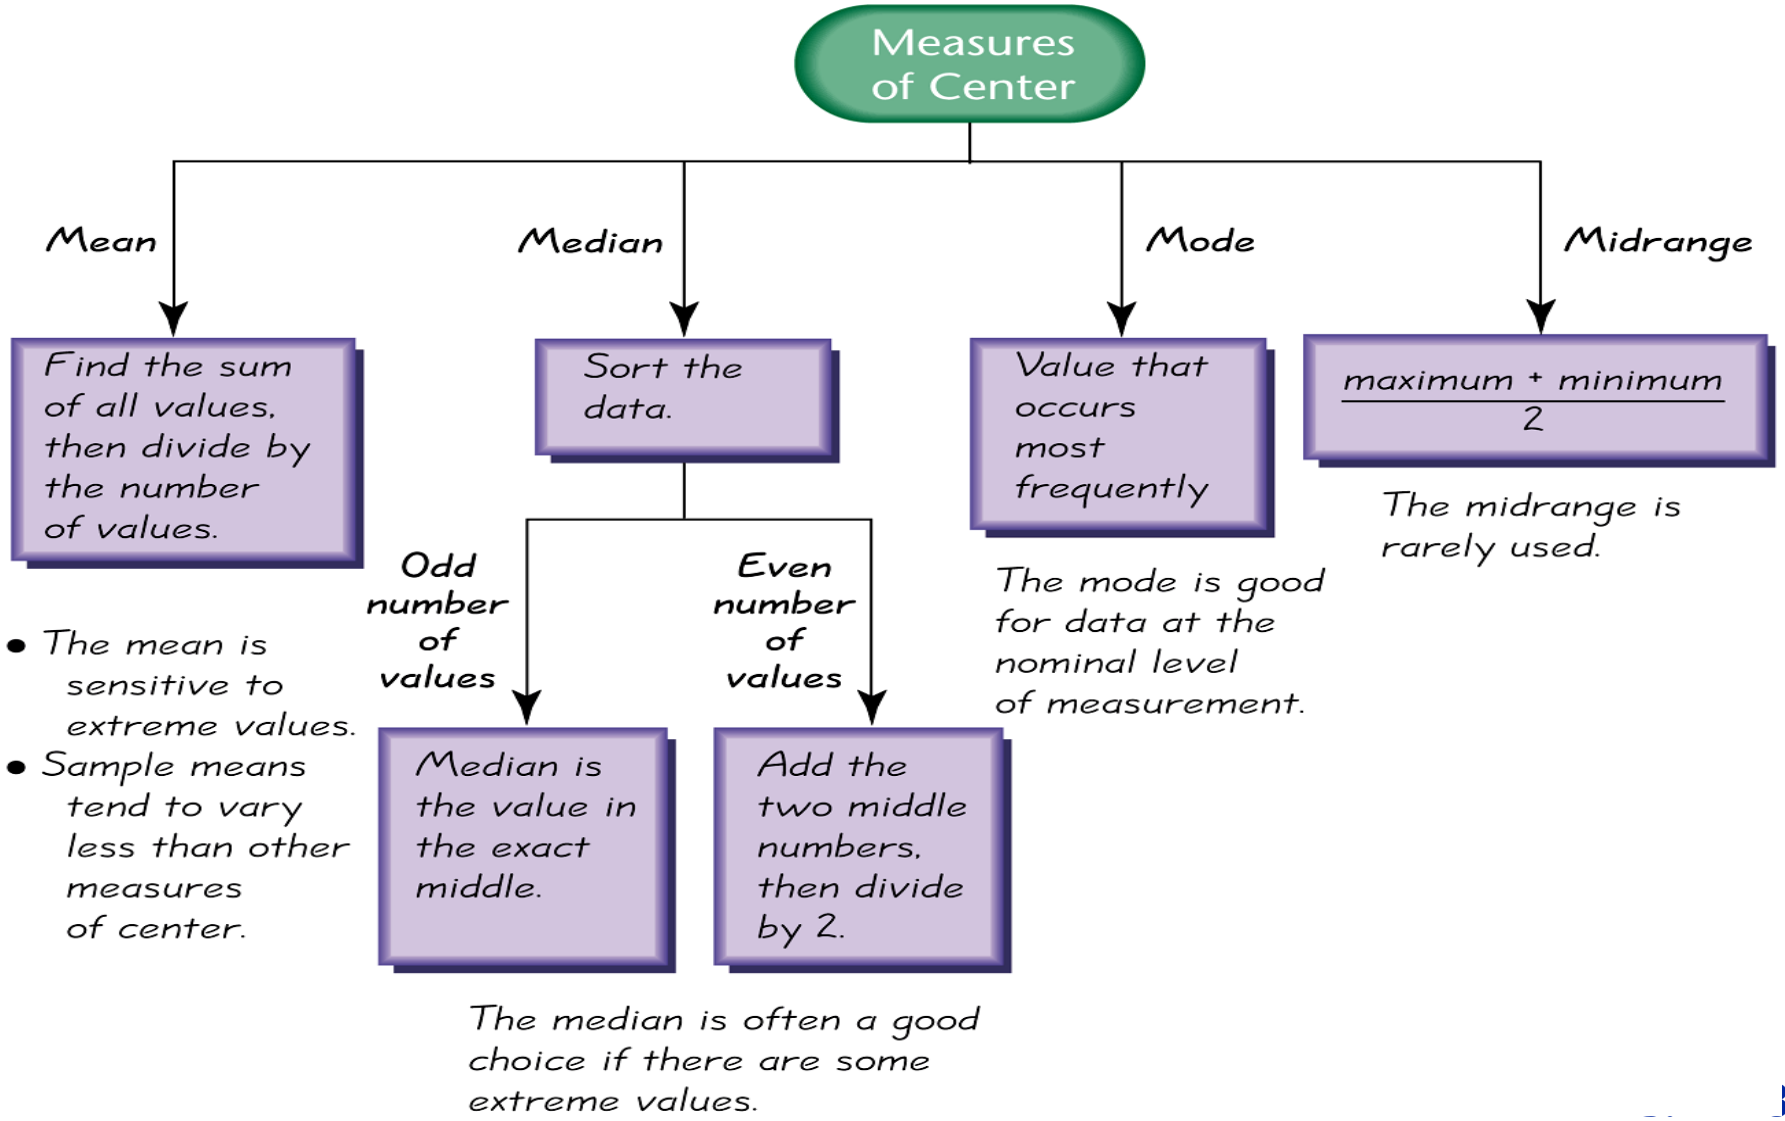
$$\bar{x} = \frac{\Sigma(f \cdot x)}{\Sigma f}$$

Média Ponderada

Quando os valores dos dados recebem pesos diferentes, podemos calcular um média ponderada.

$$\bar{x} = \frac{\Sigma (w \cdot x)}{\Sigma w}$$

Melhor Medida de Tendência Central



Assimetria e Simetria

- **Simetria**

  a distribuição de dados é simétrica se a metade esquerda de seu histograma for aproximadamente uma imagem espelhada de sua metade direita

- **Assimetria**

  a distribuição de dados é assimétrica se não for simétrica e se estender mais para um lado do que para o outro

Assimetria Esquerda ou Direita

- **Assimetria para à esquerda**

  (também chamado de assimetria negativa) tem uma cauda esquerda mais longa, a média e a mediana estão à esquerda da moda

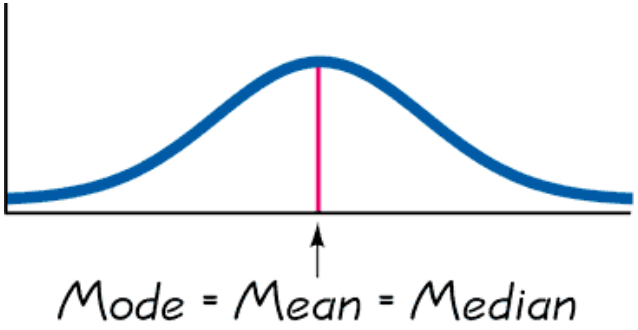
- **Assimetria para à direita**

  (também chamados positivamente assimétricos) têm uma cauda direita mais longa, a média e a mediana estão à direita da moda

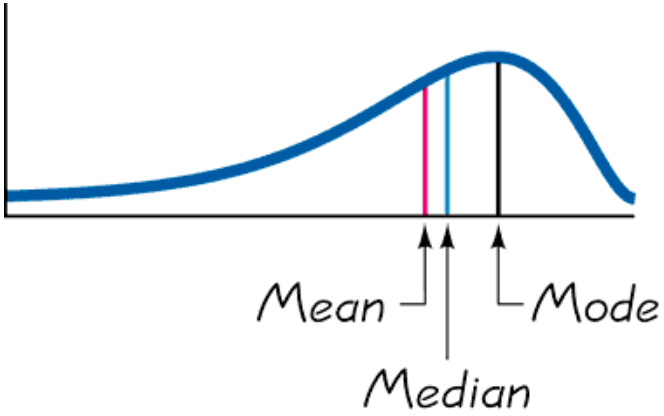
Forma da Distribuição

A média e a mediana nem sempre podem ser usadas para identificar a forma da distribuição.

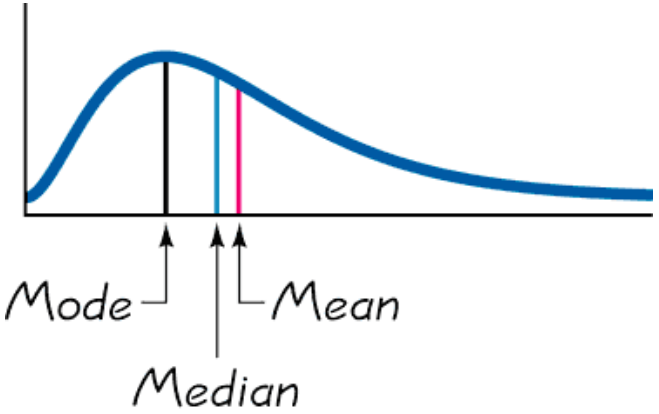
Assimetria



(b) Symmetric



(a) Skewed to the Left (Negatively)



(c) Skewed to the Right (Positively)

Recapitular

Nesta seção discutimos:

- **Tipos de medidas de centro**
  - **Média**
  - **Mediana**
  - **Moda**
- **Média de uma distribuição de frequência**
- **Médias ponderadas**
- **Melhores medidas de tendência central**
- **Assimetria**

Seção 3-3
Medidas de Dispersão



Conceito Chave

Discutir características de variação, em particular, medidas de variação, como desvio padrão, para análise de dados.

Fazer compreensão e interpretação do desvio padrão uma prioridade.

Copyright © 2010 Pearson Education

Parte 1

Conceitos Básicos de Medidas de Dispersão

Copyright © 2010 Pearson Education

Definição

A amplitude de um conjunto de valores de dados é a diferença entre o valor máximo e o valor mínimo dos dados.

Amplitude = (valor máximo) – (valor mínimo)

É muito sensível a valores extremos; portanto, não é tão útil quanto outras medidas de variação.

Copyright © 2010 Pearson Education

Regra de Arredondamento para Medidas de Variação

Ao arredondar o valor de uma medida de variação, deixe uma casa decimal a mais do que a presente no conjunto original de dados.

Arredonde apenas a resposta final, não os valores no meio de um cálculo.

Copyright © 2010 Pearson Education

Definição

O desvio padrão de um conjunto de valores amostrais, denotado por *s*, é uma medida de variação de valores em torno da média.

Copyright © 2010 Pearson Education

Fórmula do Desvio Padrão Amotral

$$s = \sqrt{\frac{\Sigma (x - \bar{x})^2}{n - 1}}$$

Copyright © 2010 Pearson Education

Desvio Padrão da Amostra (Fórmula Fácil Cálculo)

$$s = \sqrt{\frac{n\Sigma(x^2) - (\Sigma x)^2}{n\,(n-1)}}$$

Copyright © 2010 Pearson Education

Desvio padrão - Propriedades importantes

- O desvio padrão é uma medida de variação de todos os valores da **média**.
- O valor do desvio padrão ***s*** é geralmente positivo.
- O valor do desvio padrão ***s*** pode aumentar drasticamente com a inclusão de um ou mais valores discrepantes (valores de dados muito distantes de todos os outros).
- As unidades do desvio padrão ***s*** são as mesmas que as unidades dos valores de dados originais.

Copyright © 2010 Pearson Education

Comparando Variação em Diferentes Amostras

É uma boa prática comparar dois desvios padrão amostrais somente quando as médias amostrais forem aproximadamente as mesmas.

Ao comparar a variação em amostras com médias muito diferentes, é melhor usar o coeficiente de variação, que é definido mais adiante nesta seção.

Copyright © 2010 Pearson Education

Desvio Padrão Populacional

$$\sigma = \sqrt{\frac{\Sigma (x - \mu)^2}{N}}$$

Esta fórmula é semelhante à fórmula anterior, mas em vez disso, a média da população e o tamanho da população são usados.

Copyright © 2010 Pearson Education

Variância

A variância de um conjunto de valores é uma medida de variação igual ao quadrado do desvio padrão.

Variância amostral: s^2 - Quadrado do desvio padrão da amostra s

Variância populacional: σ^2 - Quadrado do desvio padrão da população σ

Copyright © 2010 Pearson Education

Estimador Imparcial

A variância amostral s^2 é um estimador não viesado da variância populacional σ^2, no que valores médios de s^2 tendem a direcionar ao valor de σ^2 em vez de tender sistematicamente a superestimar ou subestimar σ^2.

Copyright © 2010 Pearson Education

Variância - Notação

s = **desvio padrão amostral**

s^2 = ***variância amostral***

σ = **desvio padrão *populacional***

σ^2 = ***variância populacional***

Copyright © 2010 Pearson Education

Parte 2

Além do básico das medidas de variação

Copyright © 2010 Pearson Education

Regra Prática Empírica

baseia-se no princípio de que, para muitos conjuntos de dados, a grande maioria (como 95%) dos valores da amostra está dentro de dois desvios padrão da média.

Copyright © 2010 Pearson Education

Regra prática do intervalo para interpretar um valor conhecido do desvio padrão

Defina informalmente os valores *usuais* em um conjunto de dados como aqueles que são típicos e não muito extremos. Encontre estimativas aproximadas dos valores de amostra "usuais" mínimos e máximos da seguinte forma:

Valor mínimo "usual" = (média) – 2 × (desvio padrão)

Valor máximo "usual" = (média) + 2 × (desvio padrão)

Copyright © 2010 Pearson Education

Regra Geral Empírica Para Estimar Um Valor do Desvio Padrão s

Para estimar aproximadamente o desvio padrão de uma coleção de dados de amostra conhecidos, use

$$s \approx \frac{\text{intervalo}}{4}$$

onde

intervalo = (valor máximo) – (valor mínimo)

Copyright © 2010 Pearson Education

Propriedades do Desvio padrão

- Mede a variação entre os valores dos dados
- Valores próximos têm um desvio padrão pequeno, mas valores com muito mais variação têm um desvio padrão maior
- Tem as mesmas unidades de medida que os dados originais

Copyright © 2010 Pearson Education

Propriedades do Desvio padrão

Para muitos conjuntos de dados, um valor é *incomum* se diferir da média em mais de dois desvios padrão

Compare os desvios padrão de dois conjuntos de dados diferentes apenas se eles usarem a mesma escala e unidades e tiverem médias aproximadamente as mesmas

Copyright © 2010 Pearson Education

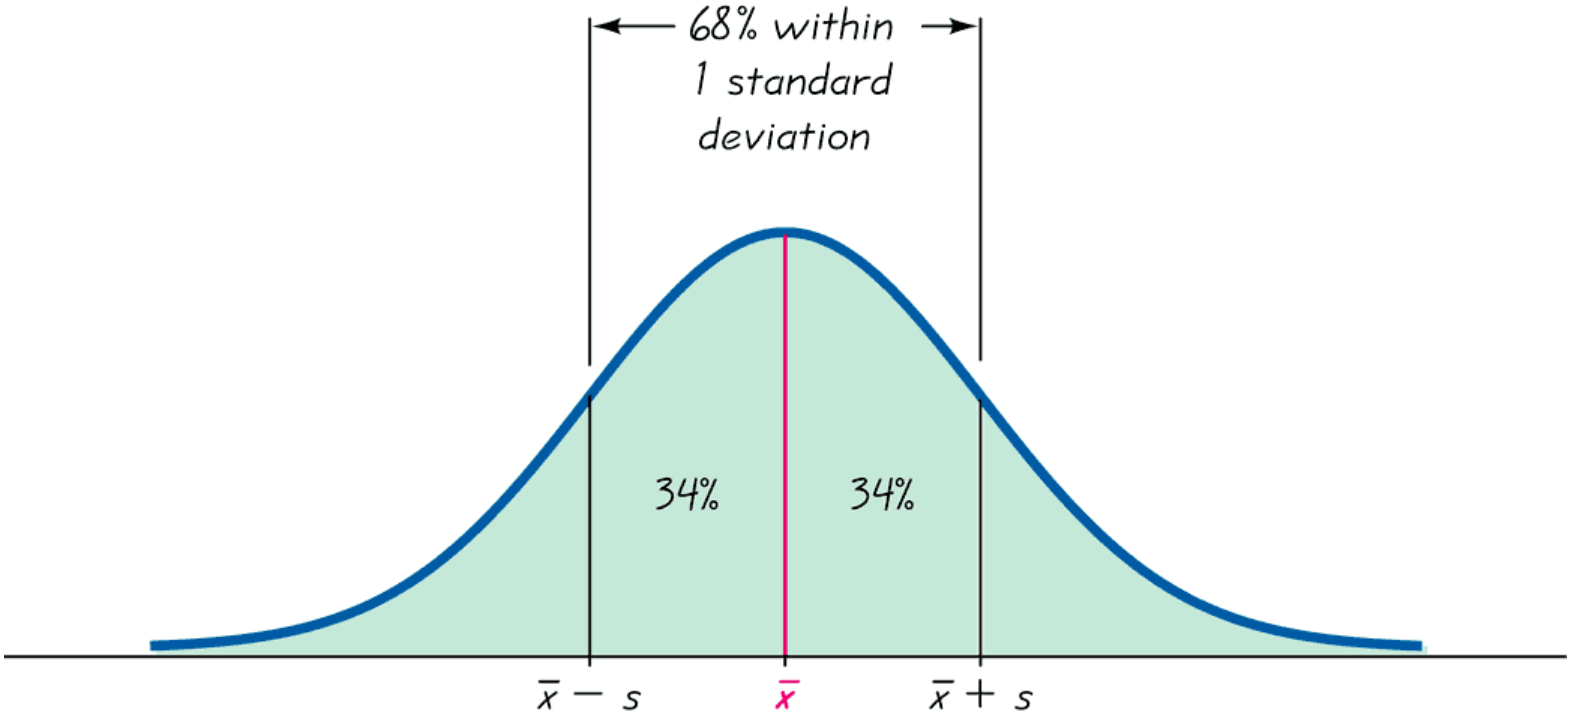
Regra empírica (ou 68-95-99,7)

Para conjuntos de dados com uma distribuição que é aproximadamente em forma de sino, as seguintes propriedades se aplicam:

- **Cerca de 68% de todos os valores estão dentro de 1 desvio padrão da média.**
- **Cerca de 95% de todos os valores estão dentro de 2 desvios padrão da média.**
- **Cerca de 99,7% de todos os valores estão dentro de 3 desvios padrão da média.**

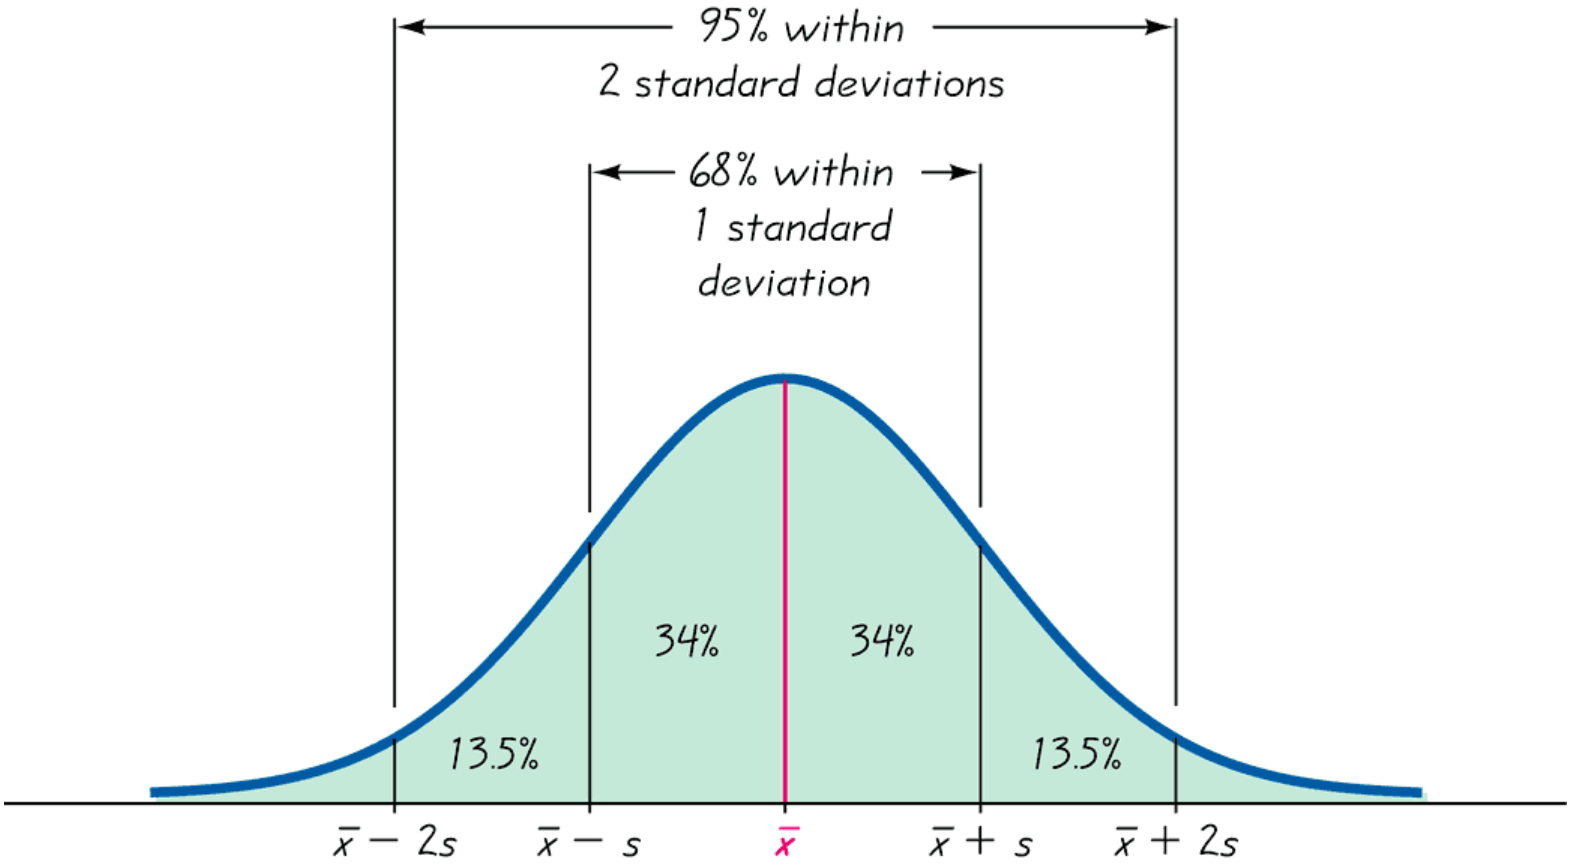
Copyright © 2010 Pearson Education

A Regra Empírica



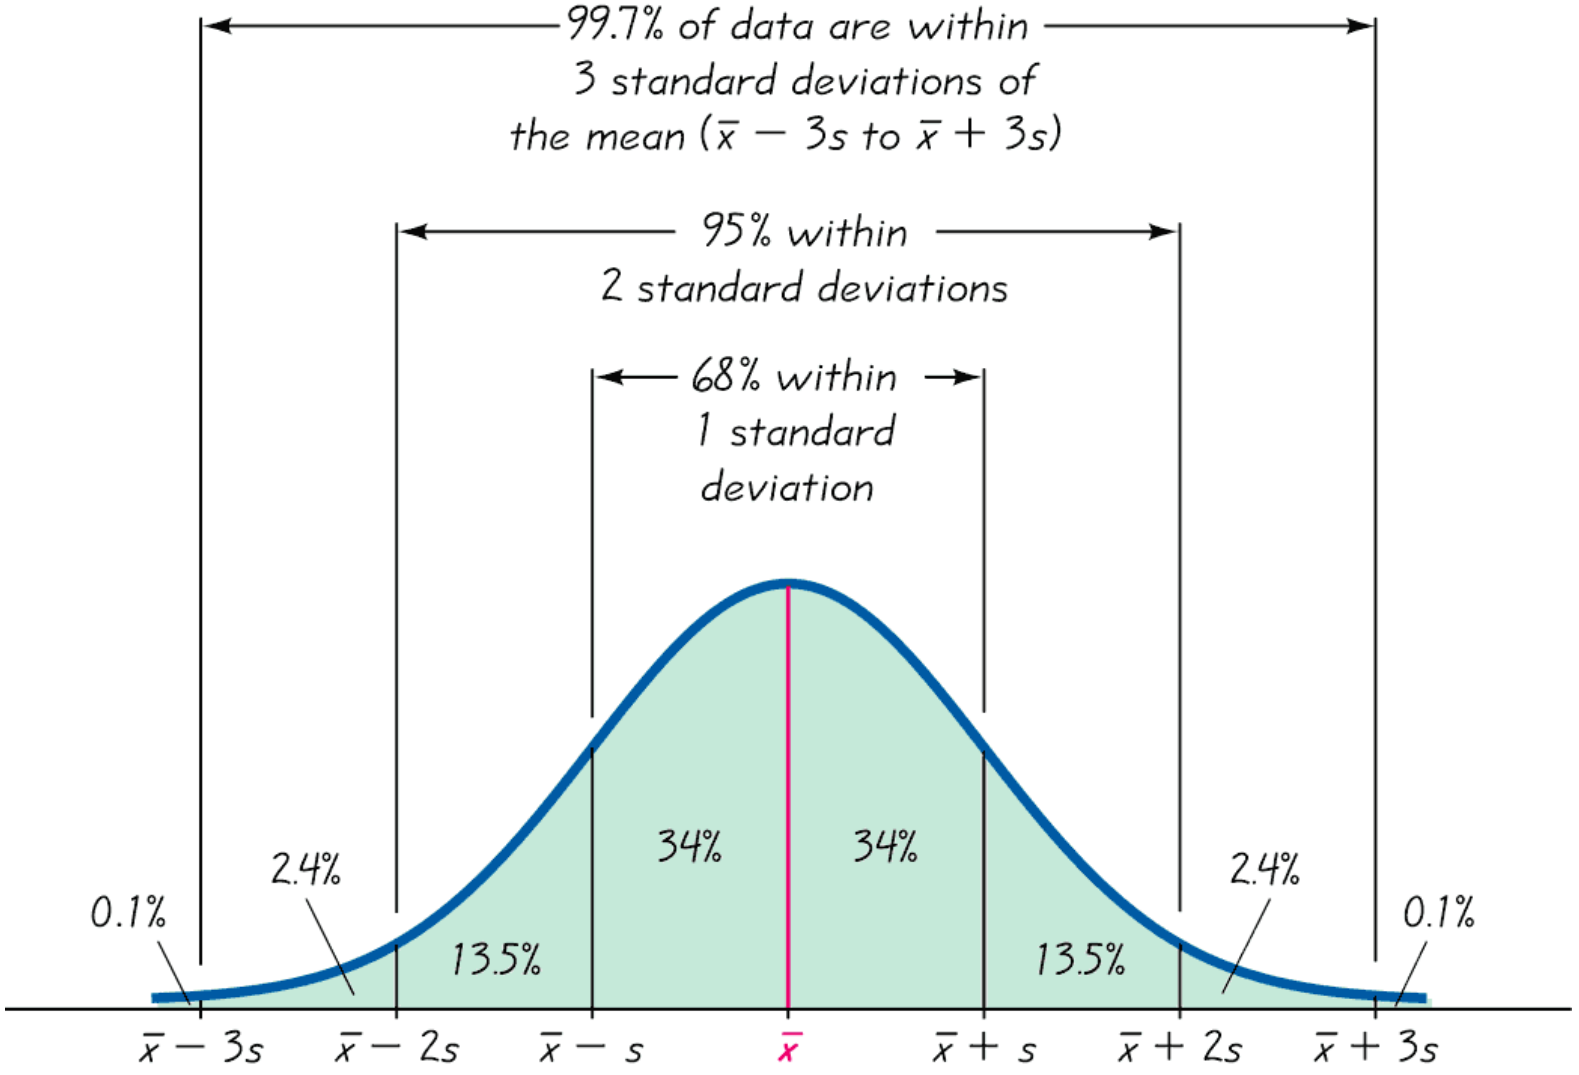
Copyright © 2010 Pearson Education

A Regra Empírica



Copyright © 2010 Pearson Education

A Regra Empírica



Copyright © 2010 Pearson Education

Teorema de Chebyshev

A proporção (ou fração) de qualquer conjunto de dados dentro de *K* desvios padrão da média é sempre pelo menos $1–1/K^2$, onde *K* é qualquer número positivo maior que 1.

- **Para K = 2, pelo menos 3/4 (ou 75%) de todos os valores estão dentro de 2 desvios padrão da média.**
- **Para K = 3, pelo menos 8/9 (ou 89%) de todos os valores estão dentro de 3 desvios padrão da média.**

Copyright © 2010 Pearson Education

Justificativa para usar n – 1 versus n

Existem apenas n – 1 valores independentes. Com uma média determinada, apenas n – 1 valores podem ser atribuídos livremente a qualquer número antes que o último valor seja determinado.

Dividir por n – 1 produz melhores resultados do que dividir por n. Faz com que s^2 atinja σ^2 enquanto a divisão por n causa s^2 subestimar σ^2.

Copyright © 2010 Pearson Education

Coeficiente de Variação

O coeficiente de variação (ou CV) para um conjunto de dados amostrais ou populacionais não negativos, expressos em porcentagem, descreve o desvio padrão em relação à média.

Amostra

$$CV = \frac{s}{\bar{x}} \cdot 100\%$$

População

$$CV = \frac{\sigma^2}{\mu} \cdot 100\%$$

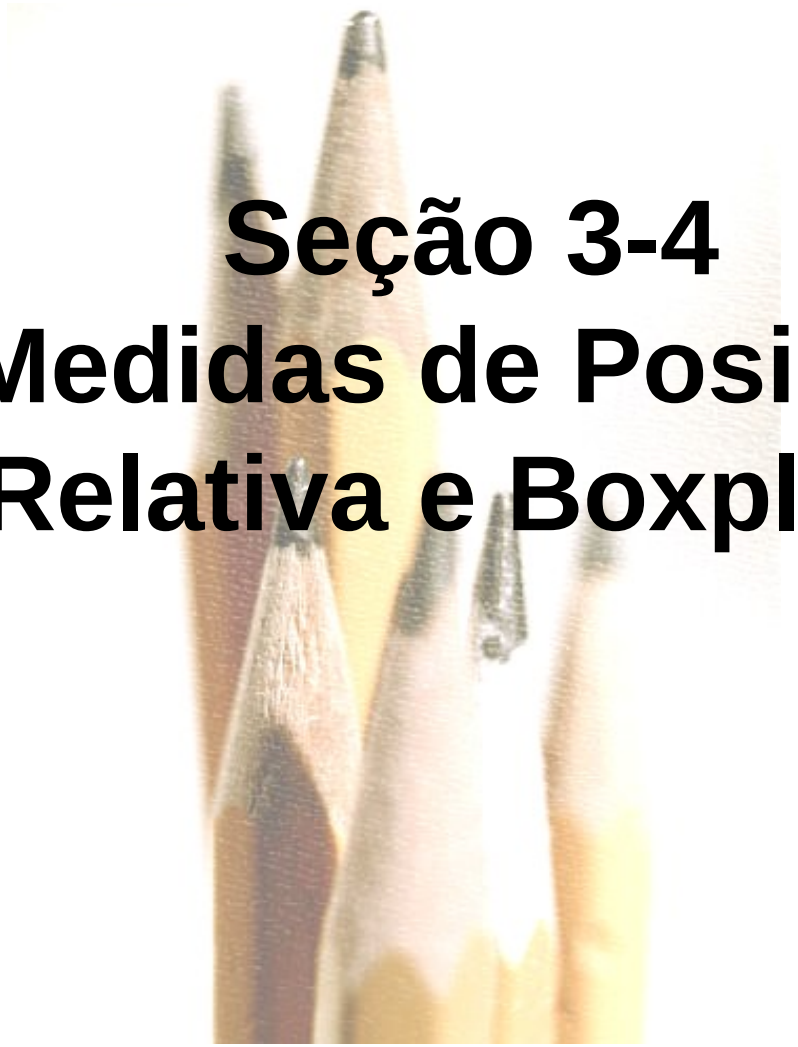
Copyright © 2010 Pearson Education

Recapitular

Nesta seção vimos:

- Amplitude
- Desvio padrão de uma amostra e população
- Variância de uma amostra e população
- Regra geral de amplitude
- Distribuição empírica
- Teorema de Chebyshev
- Coeficiente de variação (CV)

Copyright © 2010 Pearson Education



Seção 3-4
Medidas de Posição Relativa e Boxplots

Conceito chave

Esta seção apresenta medidas de posição relativa, que são números que mostram a localização de valores de dados em relação a outros valores dentro de um conjunto de dados. Eles podem ser usados para comparar valores de diferentes conjuntos de dados ou para comparar valores dentro do mesmo conjunto de dados. O conceito mais importante é o escore *z*. Também discutiremos percentis e quartis, bem como um novo gráfico estatístico chamado boxplot.

Part 1

Noções básicas de escores z, percentis, quartis e boxplots

Escore Z

- **Escore z (ou valor padronizado)**

  é o número de devios padrões que um dado valor *x* é acima ou abaixo da média

Medidas de Posição escore z

Amostral

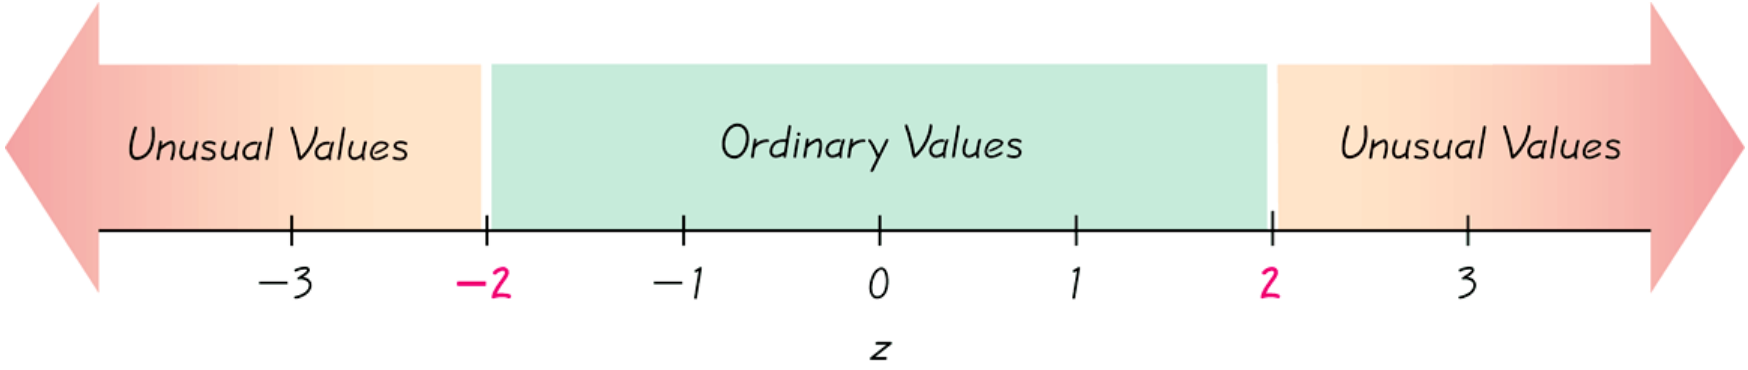
$$z = \frac{x - \bar{x}}{s}$$

População

$$z = \frac{x - \mu}{\sigma}$$

Arredonde os escores z para 2 casas decimais

Interpretando os escores Z



Sempre que um valor é menor que a média, seu escore z correspondente é negativo

Valores comuns: –2 ≤ escore z ≤ 2

Valores incomuns: escore z < –2 ou escore z > 2

Percentis

são medidas de localização. Existem 99 percentis denotado P_1, P_2, . . . P_{99}, que dividem um conjunto de dados em 100 grupos com cerca de 1% dos valores em cada grupo.

Encontrando o percentil de um valor de dados

$$\text{Percentil do valor } x = \frac{\text{número de valores menor do que } x}{\text{número total de valores}} \cdot 100$$

Convertendo do *k*-ésimo percentil para o valor de dados correspondente

Notação

$$L = \frac{k}{100} \cdot n$$

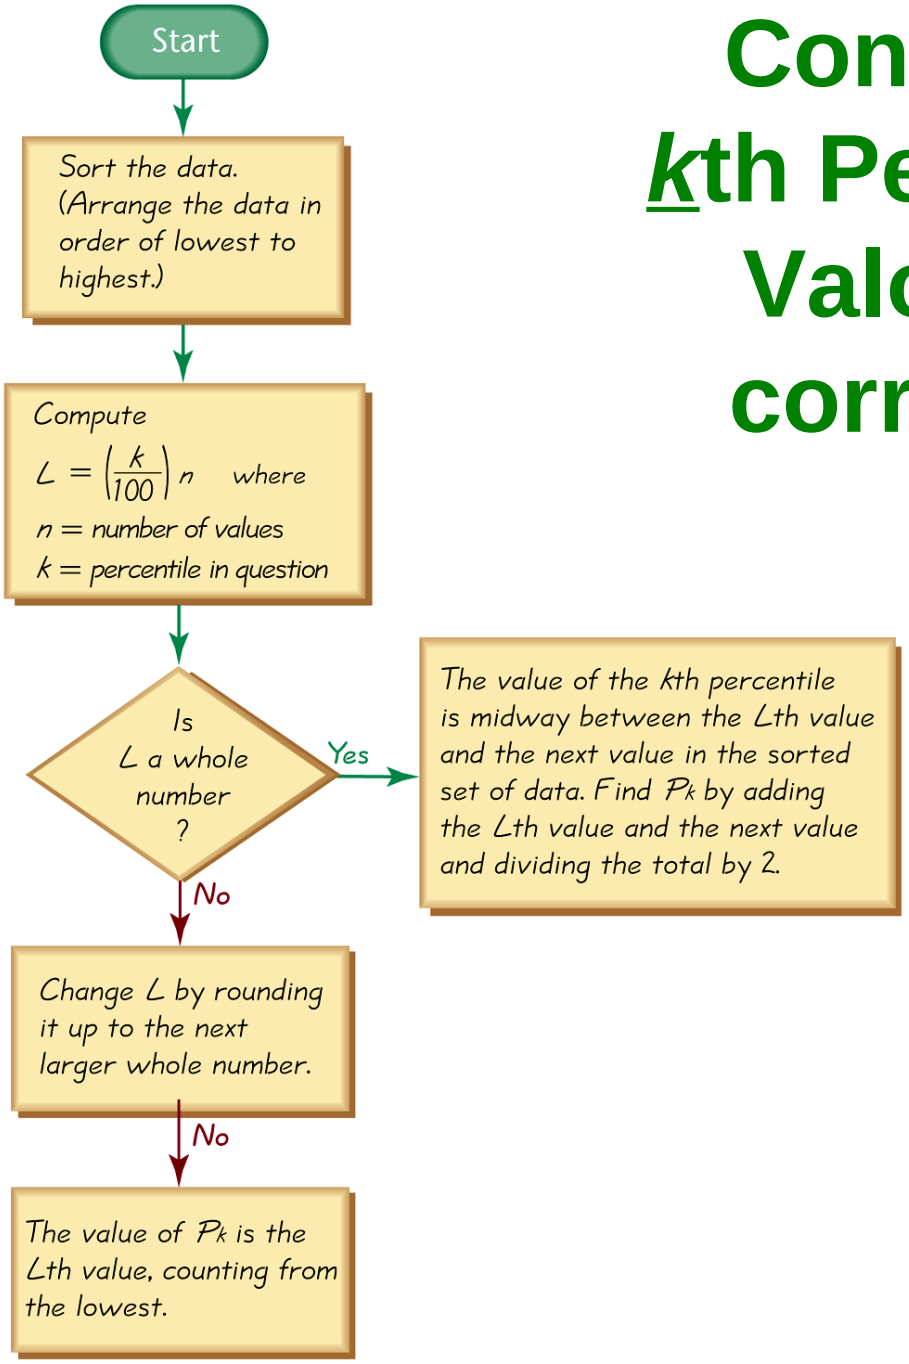
n número total de valoress no conjunto de dados

k percentil sendo usado

L localizador que dá a posição do valor

P_k kth percentil

Convertendo do *k*th Percentil para o Valor de Dados correspondente



Quartis

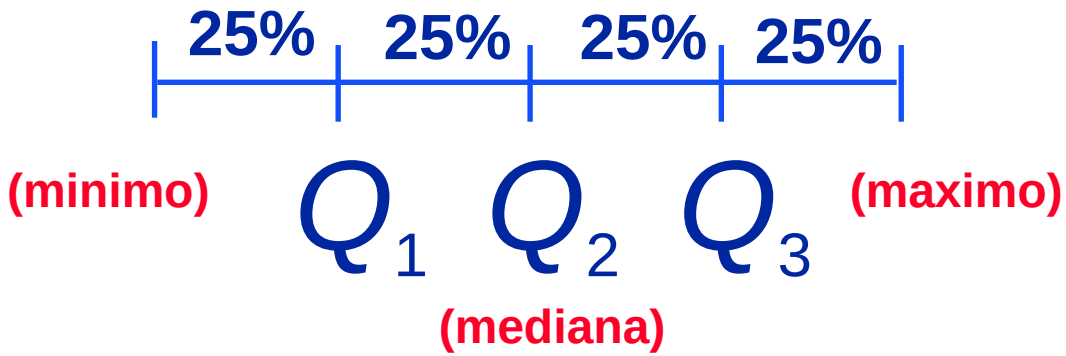
São medidas de localização, denotadas Q_1, Q_2, e Q_3, que dividem um conjunto de dados em quatro grupos com cerca de 25% dos valores em cada grupo.

- Q_1 (Primeito Quartil) separa os 25% inferiores dos valores classificados dos 75% superiores.
- Q_2 (Segundo Quartil) igual à mediana; separa os 50% inferiores dos valores classificados dos 50% superiores.
- Q_3 (Terceiro Quartil) separa os 75% inferiores dos valores classificados dos 25% superiores.

Quartis

Q_1, Q_2, Q_3

Divide escores ordenados em quatro partes iguais3



Algumas outras estatísticas

- **Faixa Interquartil (ou IQR):** $Q_3 - Q_1$
- **Faixa Semi-interquartil:** $\dfrac{Q_3 - Q_1}{2}$
- **Midquartil:** $\dfrac{Q_3 + Q_1}{2}$
- **10 – 90 Faixa Percentil:** $P_{90} - P_{10}$

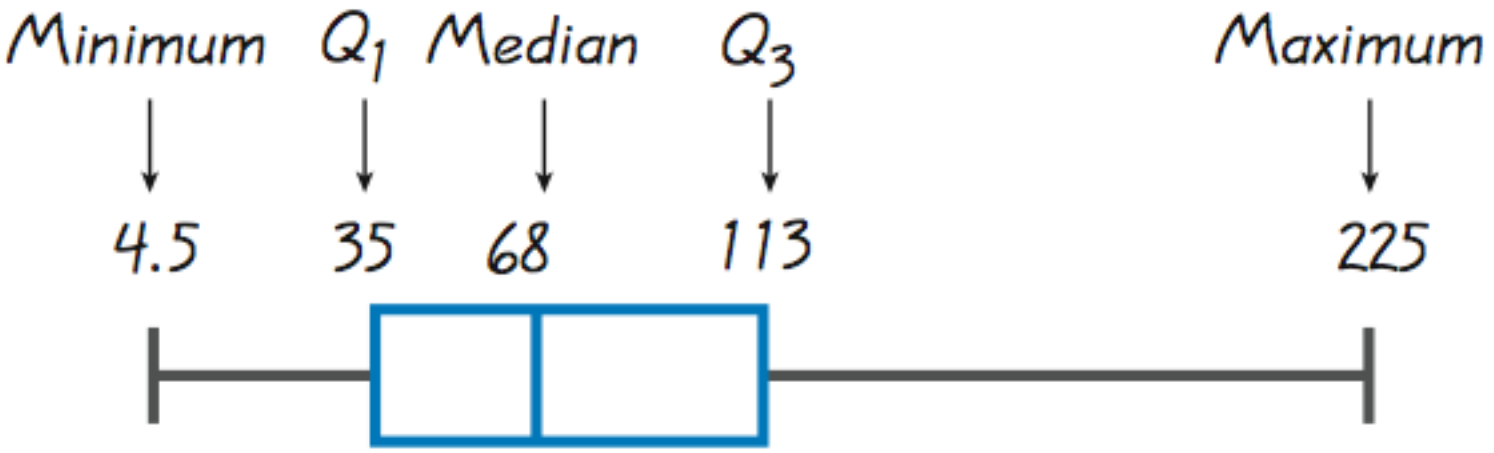
Resumo de 5 números

Para um conjunto de dados, o resumo de 5 números consiste no valor mínimo; o primeiro quartil Q1; a mediana (ou segundo quartil Q2); o terceiro quartil, Q3; e o valor máximo.

Boxplot

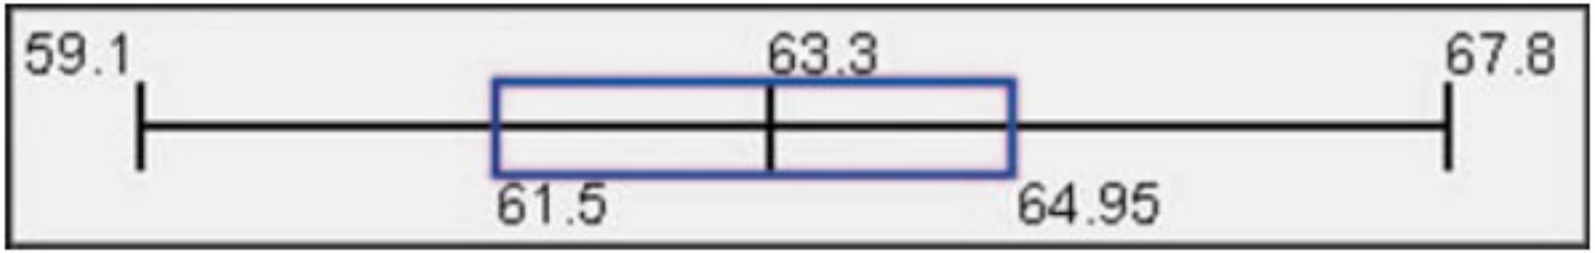
Um boxplot (ou box-and-whisker-plot) é um gráfico de um conjunto de dados que consiste em uma linha que se estende do valor mínimo ao valor máximo e uma caixa com linhas desenhadas no primeiro quartil, Q1; a mediana; e o terceiro quartil, Q3.

Boxplots



Boxplot dos valores do orçamento do filme

Boxplot – Distribuição Normal



Distribuilção Normal:
Alturas de uma amostra aleatória simples de mulheres

Boxplot – Distribuição Assimétrica



Distribuição:
Salários (em milhares de dólares) dos treinadores de futebol da NCAA

Parte 2

Outliers e Boxplots modificados

Outliers

- **Um outlier é um valor que está muito distante da grande maioria dos outros valores em um conjunto de dados.**

Princípios Importantes

- Um outlier pode ter um efeito dramático na média.
- Um outlier pode ter um efeito dramático no desvio padrão.
- Um outlier pode ter um efeito dramático na escala do histograma para que a verdadeira natureza da distribuição seja totalmente obscurecida.

Outliers para boxplots modificados

Para fins de construção de *boxplots modificados*, podemos considerar valores discrepantes como valores de dados que atendem a critérios específicos.

Em *boxplots* modificados, um valor de dados é um valor discrepante se for . . .

acima de Q_3 por um montante superior a 1.5 × IQR

ou

abaixo de Q_1 por um montante superior a 1.5 × IQR

Boxplots Modificados

Os boxplots descritos anteriormente são chamados boxplots **regular**.

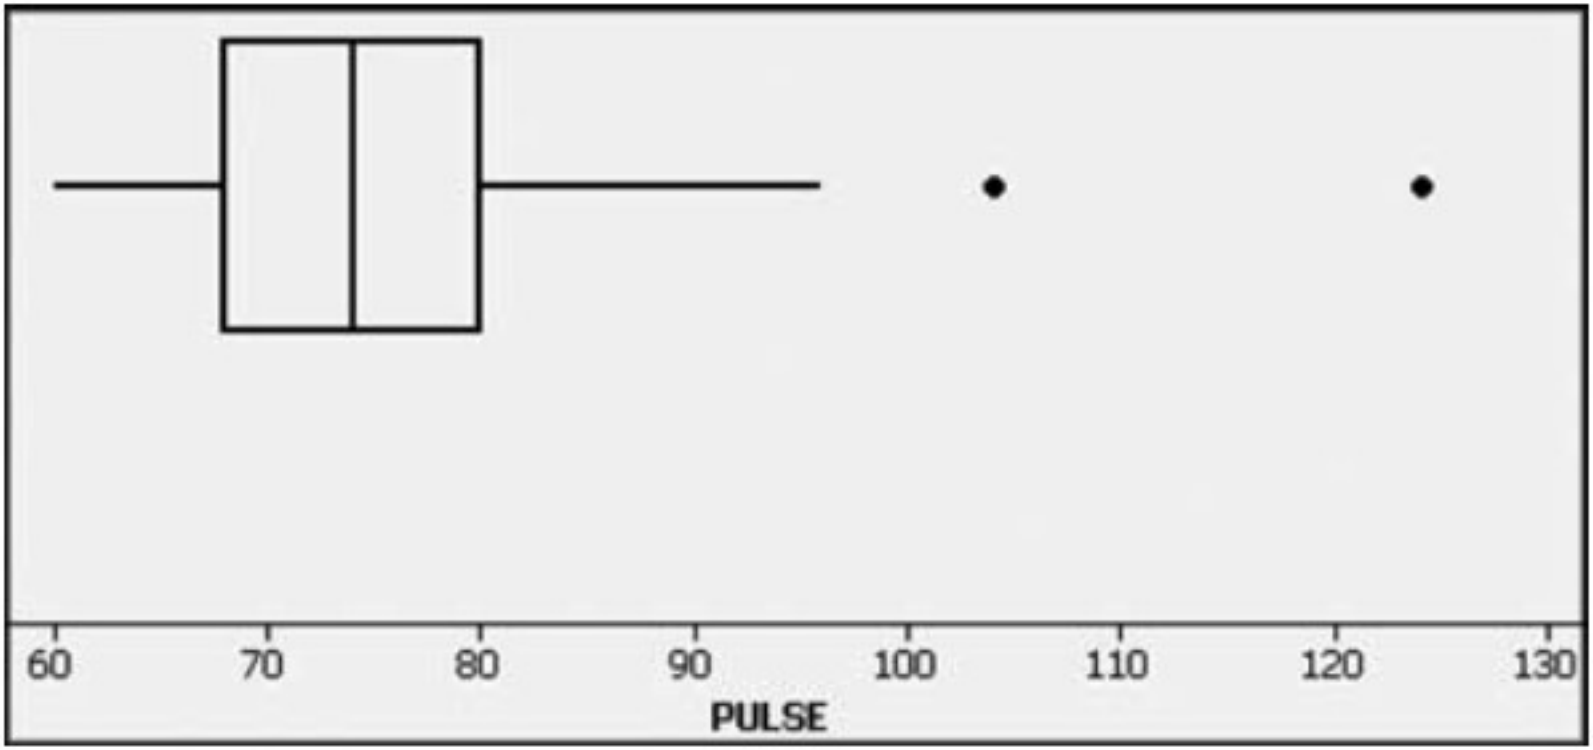
Alguns pacotes estatísticos fornecem **boxplots modificado** que representam outliers como pontos especiais.

Construção de Boxplot Modificado

Um boxplot modificado é construído com estas especificações:

- **Um símbolo especial (como um asterisco) é usado para identificar valores discrepantes.**
- **A linha horizontal sólida se estende apenas até o valor mínimo de dados que não é um valor discrepante e o valor máximo de dados que não é um valor atípico.**

Boxplots modificados - Exemplo



Taxas de pulso de mulheres listadas no Conjunto de Dados 1 no Apêndice B.

Recapitular

Nesta seção discutimos:

- **Escores z**
- **Escores z e valores não usuais**
- **Percentis**
- **Quartis**
- **Converting a percentile to corresponding data values**
- **Outras estatísticas**
- **Resumo de 5 números**
- **Boxplots e boxplots modificados**
- **Efeitos de outliers**

Juntando tudo

Sempre considere alguns fatores-chave:

- **Contexto dos dados**
- **Fonte dos dados**
- **Método de amostragem**
- **Medidas do Centro**
- **Medidas de Variação**
- **Distribuição**
- **Outliers**
- **Mudando os padrões ao longo do tempo**
- **Conclusões**
- **Implicações práticas**